

UDC: 004.896

Иерархическая когнитивная архитектура управления для мобильного робота

Аннотация

Рассматривается задача навигации мобильного робота с дифференциальным приводом в плоской среде с препятствиями и переменными свойствами поверхности. Предложена реализация трёхуровневой иерархической когнитивной архитектуры, объединяющей реактивную политику, обученную методом глубокого обучения с подкреплением, тактический линейно-квадратичный регулятор в схеме остаточной коррекции и супервизорный модуль обхода препятствий по известной карте местности. Проведён покомпонентный анализ архитектуры на двух семействах сценариев — семи конфигурациях препятствий и трёх типах опорной поверхности, по десять запусков в каждой ячейке. Показано, что распределение функций между уровнями архитектуры существенно зависит от структуры среды: супервизорный уровень разгружает реактивный при известной геометрии препятствий, но не компенсирует физических ограничений нижнего уровня при слабом сцеплении колёс с поверхностью. Все результаты воспроизведены со стопроцентной детерминированностью.

Ключевые слова: обучение с подкреплением, TD3, LQR, иерархическое управление, мобильная робототехника, STRL, residual policy, когнитивный агент

1. Введение

Автономная навигация мобильного робота в среде с препятствиями и переменными свойствами поверхности относится к задачам, в которых сходятся несколько направлений современных исследований: обучение с подкреплением, классическое управление, иерархическое планирование. Каждое из направлений действует на своём уровне абстракции и в своих допущениях, и вопрос об их интеграции в единую архитектуру остаётся открытым.

В традиции школы Осипова–Панова (ФИЦ ИУ РАН) указанный вопрос рассматривается через парадигму STRL — Strategic–Tactical–Reactive Levels [9, 8]. В STRL поведение агента распределено по трём уровням, действующим в существенно разных временных масштабах: реактивный уровень управляет моторами на миллисекундной шкале, тактический координирует локальное движение на

шкале секунд, стратегический планирует поведение на длинных горизонтах с опорой на модель мира. В диссертационной работе [9] STRL-парадигма реализована для мобильного робота МП-РМ «Зарница» с Q -обучением на реактивном уровне; в работе [11] линия исследований распространяется на мультимодальные сигналы и visual-language модели как кандидаты на роль более интегрированного когнитивного агента.

В настоящей работе предложена реализация STRL-парадигмы для случая *непрерывного* управления мобильным роботом с дифференциальным приводом. Реактивный уровень реализован обученной методом TD3 [1] нейросетевой политикой; тактический — LQR-регулятором по линеаризованной модели бокового движения; супервизорный (играющий роль стратегического уровня в нашей реализации, см. раздел 3.5) — модулем обхода препятствий по известной карте. Архитектура проверена в физическом симуляторе PyBullet на платформе Husky.

Вклад работы. (1) Реализация трёхуровневой иерархической архитектуры, соотносимой со STRL-парадигмой, для непрерывного управления мобильным роботом в среде с препятствиями и переменными свойствами поверхности. (2) Эмпирический анализ распределения функций между уровнями: 65 ablation-ячеек ($7 \times 5 + 6 \times 5$), $n = 10$ запусков в каждой, 100 % воспроизводимость. Анализ количественно показывает, что супервизорный уровень с моделью среды разгружает реактивный в задачах с известной геометрией препятствий, но не компенсирует физических ограничений нижнего уровня. (3) Открытый репозиторий с воспроизводимой реализацией.

Дальнейший текст организован следующим образом. Раздел 2 содержит обзор используемых методов и парадигм. Раздел 3 формулирует задачу и описывает архитектуру. Раздел 4 приводит результаты ablation-анализа. Раздел 5 обсуждает распределение функций между уровнями.

2. Обзор работ

2.1. Обучение с подкреплением для непрерывного управления. Для управления мобильным роботом в непрерывном пространстве действий табличные алгоритмы динамического программирования и DQN [2] неприменимы из-за невозможности представить $Q(s, a)$ для бесконечного множества действий. В таких задачах используют параметрические аппроксиматоры, обучаемые методами актёра-критика: DDPG, TD3 [1], SAC, PPO. Метод TD3 выбран как off-policy схема с подтверждённой устойчивостью обучения на робототехнических задачах и доступной эталонной реализацией в `stable-baselines3` [14].

2.2. Residual policy и LQR в управлении мобильными роботами. Идея residual policy [3, 4] возникла как ответ на ограничения обучения с подкреплением с нуля и классических контроллеров: первое требует на порядки

больше взаимодействий со средой, второе теряет качество при контактах, трении и неучтённой нелинейности. Residual policy комбинирует обучаемую политику с классическим контроллером. Линейно-квадратичный регулятор (LQR) применяется к нелинейной кинематике дифференциального привода через линеаризацию в координатах ошибки; в настоящей работе реализован lateral LQR с упрощением $e_y = 0$, оправданным постановкой навигации к точечной цели.

2.3. Иерархический RL и waypoint-планирование. Разбиение задачи управления на уровни различной временной абстракции восходит к option framework [7]. Современные иерархические схемы reinforcement learning представлены HIRO [5], в котором цели задаются в исходном пространстве с переразметкой буфера переходов, и Director [6], в котором цели задаются в латентном пространстве world model. Между двумя крайностями располагаются схемы с фиксированной верхнеуровневой структурой: waypoint-планировщики и классические геометрические алгоритмы. Супервизорный уровень в настоящей работе реализован простейшим геометрическим способом, что позволяет изолировать вклад модельного знания, отделяя его от вклада сложности алгоритма планирования.

2.4. STRL-парадигма и школа Осипова–Панова. Идея многоуровневой архитектуры мобильного робота сложилась в работах по поведенческой робототехнике 1990-х годов: subsumption architecture, систематизация трёхуровневой организации в [8], поведенческие конечные автоматы для координации реактивных модулей. В школе Осипова–Панова эта линия получила развитие в направлении когнитивных агентов со знаковой картиной мира: операции на знаковых сетях с кортежем $s = \langle n, p, m, a \rangle$ [12] соединяют сенсомоторный опыт с понятийной структурой. Диссертация [9] реализует STRL для платформы МП-РМ с Q -обучением [10] атомарных действий на реактивном уровне и иерархическим планированием на верхних. Прямой предшественник настоящей работы — статья [11] — расширяет программу школы в сторону мультимодальных сигналов и VLM-моделей; в её заключении обозначено направление дополнения VLM компонентой обучения с подкреплением и переход к интерактивной среде. Настоящая работа развивает указанное направление, реализуя STRL для непрерывного управления и проводя количественный анализ распределения функций между уровнями — вопрос, который в дискретной постановке [9] не мог быть исследован систематически.

3. Метод

3.1. Постановка задачи. Рассматривается задача навигации мобильного робота к случайной целевой точке на плоской арене с препятствиями известной геометрии и варьируемой поверхностью. Среда моделируется в PyBullet [13];

платформа — Husky, четырёхколёсный робот с дифференциальным приводом. Управление подаётся на уровне нормированных скоростей колёсных пар.

Задача формулируется как марковский процесс $\langle S, A, T, R, \gamma \rangle$. **Состояние** s образует вектор позы и кинематики робота, дополненный относительным положением цели и (при наличии препятствий) лидарными измерениями. **Действие** $a \in [-1, 1]^2$ — нормированные целевые скорости левой и правой пар колёс, преобразуемые в физические $\omega \in [-10, 10]$ рад/с. **Переход** T определяется физикой PyBullet с шагом $1/240$ с; шаг управления $1/20$ с. **Дисконт** $\gamma = 0.99$. **Арена** — плоскость 10×10 м; цель сэмплируется на расстоянии 2–5 м, радиус достижения 0.4 м. **Эпизод** завершается успехом, переворотом ($> 60^\circ$), выходом за арену, столкновением или таймаутом в 500 шагов (около 25 с). **Вознаграждение** — плотное: штраф за расстояние до цели, постоянный шаговый штраф, терминальные бонус за успех и штрафы за переворот и столкновение.




Рис. 1. Трёхуровневая иерархическая архитектура управления. Реактивный уровень (TD3) выдаёт нормированное действие a_{TD3} на каждом шаге; тактический (LQR-residual) выдаёт скалярную коррекцию u_{LQR} к угловой скорости, комбинируемую с весом α ; супервизорный (MapAware) при выполнении условия близости препятствия полностью переопределяет действие.

3.2. Иерархическая архитектура управления. В качестве организующего принципа используется парадигма многоуровневой архитектуры, восходящая к ранним работам по поведенческой робототехнике [8] и развитая для когнитивных агентов в школе Осипова–Панова [9] как Strategic–Tactical–Reactive Levels. В настоящей работе реализована адаптация STRL для непрерывного управления (рис. 1); три уровня выделяются следующим образом.

Реактивный уровень. Обученная методом TD3 политика $\pi_{TD3}: o \mapsto a$, действующая на каждом шаге управления. Опирается только на текущее наблюдение и в одиночку справляется с задачей навигации в простых средах.

Тактический уровень. LQR-регулятор с фиксированным коэффициентом, построенный по линеаризованной модели бокового движения. Выдаёт скалярную коррекцию $u_{\text{LQR}} \in [-u_{\text{max}}, u_{\text{max}}]$ к угловой скорости, комбинируемую с действием реактивного уровня по схеме residual policy [3, 4]. Опирается на аналитическую модель кинематики, обеспечивая гладкость рулевого управления независимо от качества обучения нижнего уровня.

Супервизорный уровень. Модуль обхода препятствий с использованием известной карты их положений (MapAware). Активируется при приближении робота к препятствию в передней полусфере на расстояние ниже $d_{\text{takeover}} = 1.5$ м и возвращает управление реактивно-тактической паре при выходе за $d_{\text{release}} = 2.5$ м (гистерезис предотвращает дребезг). Содержательно этот уровень играет роль стратегического в STRL с тем уточнением, что в текущей реализации он не предлагает последовательность подцелей на длинном горизонте, а перехватывает управление в опасных конфигурациях; полноценный планировщик — естественное направление развития (раздел 6).

Финальное действие на каждом шаге: при активном супервизорном уровне $a = a_{\text{MapAware}}$; иначе

$$a = a_{\text{TD3}} + \alpha \cdot \begin{bmatrix} -1 \\ +1 \end{bmatrix} u_{\text{LQR}}, \quad (1)$$

где знаки ± 1 преобразуют скалярную поправку в дифференциальный сигнал на колёса, $\alpha \in [0, 1]$ — фиксированный вес. Результат покомпонентно ограничивается отрезком $[-1, 1]$. В работе $\alpha = 0.2$ — эмпирический компромисс между подавлением высокочастотных колебаний и сохранением стратегических решений политики.

3.3. Реактивный уровень: TD3. В качестве базовой политики используется TD3 [1] — off-policy актёр-критик с двойным критиком и задержанным обновлением актёра. Актёр и оба критика — полносвязные сети со скрытыми слоями 400 и 300, нелинейность ReLU; выход актёра пропускается через tanh. Архитектура воспроизводит стандартную конфигурацию TD3 в [14].

Гиперпараметры: batch 256, оптимизатор Adam, скорость обучения 10^{-3} , $\tau = 0.005$, задержка обновления актёра $d = 2$, target-smoothing $\sigma = 0.2$ с обрезкой ± 0.5 , шум исследования $\mathcal{N}(0, 0.3)$, размер replay-буфера $2 \cdot 10^5$ в среде с препятствиями. Наблюдение включает позу, скорости, ориентацию (косинус и синус угла рыскания) и относительное положение цели; в среде с препятствиями добавляются 16 лучей лидара. Наблюдение *привилегированное* — эквивалентно идеальной локализации, что отделяет вопросы управления от вопросов восприятия.

3.4. Тактический уровень: LQR-residual. В системе координат, связанной с прямой от робота к цели, состояние ошибки $e = [e_y, e_\theta]^T$ (поперечное

отклонение и отклонение курса) при фиксированной опорной скорости v_{ref} и малых отклонениях подчиняется линеаризованной модели:

$$\dot{e} = \begin{bmatrix} 0 & v_{\text{ref}} \\ 0 & 0 \end{bmatrix} e + \begin{bmatrix} 0 \\ -1 \end{bmatrix} \omega. \quad (2)$$

LQR находит управление $\omega = -Ke$, минимизирующее $J = \int_0^\infty (e^\top Q e + R\omega^2) dt$ с $Q = \text{diag}(2.0, 1.0)$, $R = 5.0$. Преобладание штрафа на управление ($R > Q_{ii}$) даёт мягкие, не доминирующие коррекции. Матрица K вычисляется один раз через решение уравнения Риккати (`scipy.linalg.solve_continuous_are`).

В реализации e_y обнуляется на каждом шаге: опорная прямая переопределяется как линия от текущей позы робота к цели, и накопленного поперечного отклонения относительно этой динамической прямой не возникает. Закон вырождается в $\omega = -k_\theta e_\theta$, структурно Р-регулятор по углу с коэффициентом из LQR-задачи. Это сознательное упрощение: в схеме residual policy LQR подавляет высокочастотные колебания курса, не вмешиваясь в стратегические решения политики. Выход ω ограничивается $[-u_{\text{max}}, u_{\text{max}}]$, $u_{\text{max}} = 0.3$.

3.5. Супервизорный уровень: обход с использованием карты. Уровень получает карту препятствий — список цилиндров $\{(o_i^x, o_i^y, r_i)\}$. В каждый шаг вычисляются расстояния до краёв препятствий в передней полусфере $\pm\pi/2$ относительно курса; применяется двухпороговая логика с гистерезисом (d_{takeover} , d_{release}). При активном режиме контроллер задаёт прямолинейное движение со скоростью $v_{\text{sup}} = 0.4$ м/с и угловую скорость, поворачивающую робот от ближайшего препятствия: $\omega_{\text{sup}} = k_{\text{turn}} \cdot \text{sign}(-\theta_{\text{nearest}})$, $k_{\text{turn}} = 1.5$, где θ_{nearest} — локальный угол на ближайшее препятствие в передней полусфере.

Простота алгоритма преднамеренна: в задачах с известной геометрией эффективное поведение часто достижимо без оптимизационного планировщика, и упрощение позволяет изолировать вклад *знания карты* как такового. В работе также рассмотрен альтернативный реактивный супервизор по лидарным дальностям (LidarAvoid) для сравнения вкладов модельного и сенсорного знания о препятствии.

4. Эксперименты

4.1. Конфигурация и метрики. Эксперименты проведены на сервере 8 ядер Ryzen 9 9950X / 16 ГБ RAM без GPU; PyBullet 3.2 в безголовом режиме, шесть параллельных сред через SubprocVecEnv. Сиды детерминированы: $\{200, 201, \dots, 209\}$; $n = 10$ запусков в каждой ячейке таблицы.

Основная метрика — доля успешных эпизодов (success rate). Дополнительно фиксируются длина эпизода, гладкость управления, максимальная линейная

скорость, доля времени в супервизорном режиме. Сравниваются пять архитектурных режимов: **TD3**, **TD3+LQR**, **TD3+LidarAvoid**, **TD3+MapAvoid**, **TD3+MapAvoid+LQR**.

4.2. Эксперимент А: множественные конфигурации препятствий.

В первой серии оценивается зависимость от геометрии препятствий. Семь детерминированных конфигураций представляют качественно разные ситуации: одиночное препятствие на прямой; два препятствия со смещением; коридор из трёх; барьер с проходом; слалом; диагональное расположение цели; широкое препятствие.

Сценарий	TD3	+LQR	+Lidar	+Map	+Map+LQR
single_on_line	0/10	0/10	0/10	10/10	10/10
two_offset	0/10	0/10	0/10	10/10	10/10
three_corridor	0/10	0/10	0/10	0/10	0/10
barrier_with_gap	10/10	10/10	10/10	0/10	0/10
slalom	0/10	0/10	0/10	0/10	0/10
diagonal_goal	10/10	10/10	10/10	10/10	10/10
wide_obstacle	0/10	0/10	10/10	10/10	10/10

Таблица 1. Эксперимент А: доля успешных эпизодов (из 10 запусков на сидах 200–209) для семи конфигураций препятствий и пяти архитектурных режимов. Все ячейки 100 % детерминированы.

Сценарий *diagonal_goal* без препятствий на прямой к цели решается всеми режимами и служит контролем — включение тактического или супервизорного уровней не деградирует реактивный. Сценарии *three_corridor* и *slalom* не решаются ни одним режимом, фиксируя верхнюю границу применимости архитектуры.

Содержательное различие проявляется на четырёх оставшихся сценариях. В *single_on_line* и *two_offset* разница максимальна: успех 100 % даёт только включение MapAvoid, тогда как реактивный и тактический уровни не справляются. Обученная политика идёт по прямой в цель, не учитывая препятствие, и сталкивается; LQR-residual подавляет колебания, но не меняет общую стратегию. Только модельное знание карты позволяет перенаправить движение.

Обратный паттерн виден в *barrier_with_gap*, где прямой путь проходит через узкий проход в барьере. Все варианты с MapAvoid не справляются (0/10), а полностью реактивные и реактивный с лидарным супервизором — справляются полностью. Причина в логике MapAvoid: широкий радиус takeover заставляет супервизор обходить барьер целиком, тогда как геометрический проход в нём проходим напрямую.

В *wide_obstacle* наибольшую устойчивость показывает лидарный супервизор: широкое препятствие аппроксимировано в карте цилиндром малого радиуса, и MapAvoid не активируется на нужной дистанции; лидарные лучи фиксируют препятствие напрямую. Это указывает на ограниченность модельного знания: оно полезно при адекватной геометрической репрезентации препятствий.




Рис. 2. Эксперимент А, сценарий с одиночным препятствием на прямой к цели: траектории пяти архитектурных режимов. Реактивные и реактивно-тактический варианты сталкиваются с препятствием (точки разрыва траектории); включение супервизорного уровня обеспечивает обход.

Воспроизводимость. Все ячейки таблицы 1 проверены повторными запусками. Результаты полностью детерминированы: каждая ячейка имеет однозначный исход, без промежуточных значений. Это свойство сцены, следствие детерминированности PyBullet при фиксированных стартовых условиях, фиксированных весов политики и отсутствия стохастичности в верхних уровнях.

4.3. Эксперимент В: переменные свойства поверхности. Во второй серии оценивается влияние свойств опорной поверхности. Реализованы три условия: *NORMAL* (трение 0.9), *ICE* (трение 0.05) и *SAND* (трение 0.6 с дополнительным сопротивлением качению). Каждое условие тестируется в двух конфигурациях: *empty* и *with_obstacle*, $n = 10$.

Поверхность	Конфиг.	TD3	+LQR	+Lidar	+Map	+Map+LQR
NORMAL	empty	10/10	10/10	10/10	10/10	10/10
NORMAL	+ obst.	0/10	0/10	0/10	10/10	10/10
ICE	empty	10/10	10/10	10/10	10/10	10/10
ICE	+ obst.	0/10	0/10	0/10	0/10	0/10
SAND	empty	10/10	10/10	10/10	10/10	10/10
SAND	+ obst.	0/10	0/10	0/10	10/10	10/10

Таблица 2. Эксперимент В: доля успешных эпизодов (из 10) для трёх типов поверхности и двух конфигураций. Модель TD3 v3 обучена на детерминированном сценарии с препятствием на NORMAL и используется во всех ячейках без переобучения.

В пустой арене реактивный уровень одинаково успешен на всех трёх поверхностях, хотя максимальная скорость различается на порядок (ICE: ~ 0.1 м/с, SAND: ~ 0.8 м/с, NORMAL: ~ 2.8 м/с). Политика обладает достаточной общностью для адаптации линейной скорости под трение, хотя обучалась только на NORMAL.

В присутствии препятствия на NORMAL и SAND включение MapAvoid решает задачу полностью; результат согласуется с экспериментом А. На ICE с препятствием не справляется ни один режим: при попытке обхода низкое трение приводит к проскальзыванию и столкновению. Это принципиальное наблюдение: *знание карты не компенсирует физическое ограничение нижнего уровня.*

Дополнительное дообучение политики на расширенном распределении поверхностей (continued training, 700 тыс. шагов, распределение 50/30/20 % между NORMAL/SAND/ICE) частично снимает ограничение: ICE+obstacle поднимается до 5/10 с тактическим уровнем, но NORMAL+obstacle в режиме MapAvoid+LQR деградирует с 10/10 до 7/10. Это фиксирует trade-off между общностью и пиковой эффективностью, типичный для transfer learning.

5. Обсуждение

Реактивный уровень компетентен в условиях свободного движения. На всех трёх типах поверхности в пустой арене политика достигает 100 % успеха, адаптируя линейную скорость без переобучения. Это соответствует типичной области реактивного управления в STRL: действие на коротком горизонте без обращения к модели среды.

Тактический уровень не меняет стратегические решения. Включение LQR-residual поверх реактивного уровня не меняет долю успеха ни в одной ячейке таблиц 1, 2. LQR подавляет высокочастотные колебания курса (что фиксируется в

дополнительных измерениях гладкости управления), но не влияет на способность преодолевать препятствия. Это согласуется с теоретической ролью тактического уровня в STRL [9].

Супервизорный уровень разгружает реактивный при адекватной модели. Эксперимент А показывает, что в *single_on_line* и *two_offset* включение MapAvoid обеспечивает 100 % успех там, где реактивный уровень не справляется. Это типичная демонстрация полезности стратегического уровня в STRL: знание среды позволяет принимать решения, которых реактивный уровень не может. Обратный эффект в *barrier_with_gap* и в *wide_obstacle* указывает на чувствительность супервизора к параметрам геометрической модели: полезность модельного знания не абсолютна.

Модельное знание не компенсирует физического ограничения нижнего уровня. Эксперимент В: на ICE+obstacle ни один режим не решает задачу, включая полную трёхуровневую архитектуру. Супервизор предлагает корректную стратегию обхода, тактический уровень обеспечивает гладкое управление, но низкое трение приводит к проскальзыванию независимо от стратегии. Эксперимент с дообучением частично снимает ограничение, формируя trade-off с пиковой скоростью на отдельной поверхности.

Общая трактовка. Полезность верхних уровней архитектуры функционально определена структурой среды и качеством нижних уровней, а не абсолютна. В свободном движении полезность нулевая; в задачах с известной геометрией супервизорный уровень становится критичен; в задачах с физическими ограничениями нижнего уровня ни один из верхних не помогает.

Ограничения. Использован простейший геометрический супервизор без оптимизационного планирования; реактивный уровень обучен с привилегированным наблюдением; реальная робототехническая платформа не задействована.

6. Заключение

В работе реализована и эмпирически исследована трёхуровневая иерархическая архитектура управления мобильным роботом с дифференциальным приводом, соотносимая со STRL-парадигмой школы Осипова–Панова. Реактивный уровень — обученная политика TD3, тактический — LQR-residual с упрощением $e_y = 0$, супервизорный — модуль обхода препятствий по известной карте.

Ablation-анализ на семи конфигурациях препятствий и трёх типах поверхности количественно характеризует распределение функций. Тактический уровень не меняет долю успеха, но улучшает гладкость. Супервизорный разгружает реактивный при известной геометрии препятствий, но не справляется при слабом сцеплении колёс. Все результаты воспроизведены со 100 % детерминированностью.

Направления развития: **(1) Стратегический уровень** в его полной STRL-формулировке — оптимизационный планировщик последовательности подцелей на длинном горизонте — требует реализации и сравнения с использованным здесь упрощённым вариантом. **(2) Visual-language интерфейс** к стратегическому уровню, в духе [11], естественно дополняет архитектуру визуальной модальностью. **(3) Реальная робототехническая платформа** — ключевое направление группы [9]; перенос из PyBullet на платформу с ROS требует адаптации наблюдения (восстановление позы из SLAM) и проверки устойчивости к sim-to-real разрыву.

ЛИТЕРАТУРА

1. Fujimoto S., van Hoof H., Meger D. Addressing function approximation error in actor-critic methods // Proc. of ICML. 2018. P. 1587–1596.
2. Mnih V., Kavukcuoglu K., Silver D. et al. Human-level control through deep reinforcement learning // Nature. 2015. V. 518. P. 529–533.
3. Silver T., Allen K., Tenenbaum J., Kaelbling L. Residual policy learning // arXiv preprint arXiv:1812.06298. 2018.
4. Johannink T., Bahl S., Nair A. et al. Residual reinforcement learning for robot control // Proc. of ICRA. 2019. P. 6023–6029.
5. Nachum O., Gu S., Lee H., Levine S. Data-efficient hierarchical reinforcement learning // Proc. of NeurIPS. 2018. P. 3303–3313.
6. Hafner D., Lee K.-H., Fischer I., Abbeel P. Deep hierarchical planning from pixels // Proc. of NeurIPS. 2022.
7. Sutton R. S., Precup D., Singh S. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning // Artificial Intelligence. 1999. V. 112. P. 181–211.
8. Gat E. On three-layer architectures // Artificial Intelligence and Mobile Robots / D. Kortenkamp, R. Bonasso, R. Murphy (eds.). AAAI Press, 1998. P. 195–210.
9. Киселёв Г. А. Интеллектуальная система планирования поведения коалиции робототехнических агентов со STRL архитектурой: дис. ... канд. техн. наук. Москва, 2020. 117 с.
10. Киселёв Г. А., Панов А. И. Иерархическое психологически-инспирированное планирование для интеллектуальных динамических систем // Известия РАН. Теория и системы управления. 2020. № 1. С. 123–137.
11. Вейценфельд Д. А., Киселёв Г. А. Метод синтеза поведения когнитивного агента на основе обработки мультимодальных сигналов // Моделирование и анализ данных. 2024. Т. 14. № 4. С. 45–62.

12. Osipov G. S., Panov A. I. Relationships and operations in a sign-based world model of the actor // Scientific and Technical Information Processing. 2018. V. 45. P. 317–330.
13. Coumans E., Bai Y. PyBullet, a Python module for physics simulation for games, robotics and machine learning. 2016–2021. URL: <http://pybullet.org>
14. Raffin A., Hill A., Gleave A. et al. Stable-Baselines3: Reliable reinforcement learning implementations // Journal of Machine Learning Research. 2021. V. 22. № 268. P. 1–8.