

004.896

Иерархическая STRL-архитектура управления для мобильного робота: интеграция TD3, LQR-residual и обхода препятствий с использованием карты

Аннотация

Рассматривается задача навигации мобильного робота с дифференциальным приводом в плоской среде с препятствиями и переменными свойствами поверхности. Предложена реализация трёхуровневой иерархической архитектуры, соотносимой с парадигмой Strategic-Tactical-Reactive Levels (STRL) школы Осипова-Панова и объединяющей реактивную политику TD3, тактический слой LQR-residual и супервизорный модуль обхода препятствий на основе известной карты. Проведён ablation-анализ на десяти сидах для двух семейств сценариев: семи конфигураций препятствий и трёх типов поверхностей. Показано, что распределение функций между уровнями архитектуры существенно зависит от структуры среды: супервизорный уровень разгружает реактивный в задачах с известной геометрией препятствий, но не компенсирует физических ограничений нижнего уровня в условиях слабого сцепления колёс. Все результаты воспроизводимы со 100 % детерминированностью.

Ключевые слова: обучение с подкреплением, TD3, LQR, иерархическое управление, мобильная робототехника, STRL, residual policy, когнитивный агент

1. Введение

Автономная навигация мобильного робота в среде с препятствиями и переменными свойствами поверхности — задача, в которой соприкасаются несколько направлений современных исследований искусственного интеллекта: обучение с подкреплением, классическое управление, иерархическое планирование. Каждое из направлений решает её на своём уровне абстракции и в своих допущениях, и вопрос об их интеграции в единую архитектуру управления остаётся открытым.

В традиции отечественной школы когнитивных агентов (школа Осипова-Панова, ФИЦ ИУ РАН) указанный вопрос рассматривается через парадигму STRL — Strategic-Tactical-Reactive Levels [9, 8]. В STRL поведение агента распределено по трём уровням, действующим в существенно разных временных

масштабах: реактивный уровень управляет моторами на миллисекундной шкале, тактический — координирует локальное движение на шкале секунд, стратегический — планирует поведение на длинных горизонтах на основе модели мира. В диссертационной работе [9] STRL-парадигма была реализована для мобильного робота МП-РМ «Зарница» с Q-обучением на реактивном уровне; продолжение этой линии в работе [11] расширяет внимание на мультимодальные сигналы и переходит к VLM-моделям как кандидатам на роль более интегрированного агента.

В настоящей работе предложена реализация STRL-парадигмы для случая непрерывного управления мобильным роботом с дифференциальным приводом. Реактивный уровень реализован обученной методом TD3 [1] нейросетевой политикой; тактический — LQR-регулятором по линеаризованной модели бокового движения; супервизорный (в нашей реализации играющий роль стратегического уровня, см. раздел 3.5) — модулем обхода препятствий на основе известной карты. Архитектура проверена в физическом симуляторе PyBullet на платформе Husky на двух семействах сценариев: семь конфигураций препятствий с разной геометрией и три типа поверхности.

Вклад работы. (1) Реализация трёхуровневой иерархической архитектуры, соотносимой со STRL-парадигмой, для непрерывного управления мобильным роботом в среде с препятствиями и переменными свойствами поверхности. (2) Эмпирический анализ распределения функций между уровнями на двух семействах сценариев ($7 \times 5 + 6 \times 5 = 65$ ablation-ячеек, $n = 10$ запусков в каждой, 100 % воспроизводимость). Анализ показывает, что супервизорный уровень с моделью среды разгружает реактивный в задачах с известной геометрией препятствий, но не компенсирует физические ограничения нижнего уровня в условиях слабого сцепления колёс с поверхностью. (3) Открытый репозиторий с воспроизводимой реализацией всех описанных уровней, обученной моделью и протоколом экспериментов.

Дальнейший текст организован следующим образом. В разделе 2 приводится обзор работ по основным используемым методам и парадигмам. В разделе 3 формулируется задача и описывается архитектура управления. Раздел 4 содержит результаты ablation-анализа на двух семействах сценариев. Раздел 5 обсуждает распределение функций между уровнями архитектуры и ограничения подхода. Раздел 6 формулирует выводы и направления дальнейших исследований.

2. Обзор работ

2.1. Обучение с подкреплением для непрерывного управления. Задача управления мобильным роботом в непрерывном пространстве действий относится к классу проблем, для которых табличные алгоритмы динамического

программирования и DQN [2] неприменимы из-за невозможности представить $Q(s, a)$ для бесконечного множества действий. В таких задачах используют параметрические аппроксиматоры Q_ϕ и π_θ , обучаемые методами актёр-критика: DDPG, TD3 [1], SAC, PPO. В настоящей работе используется TD3 как off-policy метод с подтверждённой устойчивостью обучения на робототехнических задачах и доступной эталонной реализацией в `stable-baselines3` [14].

2.2. Residual Policy и LQR в управлении мобильными роботами.

Идея residual policy learning [3, 4] возникла как ответ на ограничение обучения с подкреплением с нуля и классических контроллеров: первое требует на порядки больше взаимодействий со средой, второе теряет качество при контактах, трении и неучтённой нелинейности. Residual policy комбинирует обучаемую политику с классическим контроллером, опираясь на сильные стороны обоих. Линейно-квадратичный регулятор (LQR) применяется к нелинейной кинематике дифференциального привода через линеаризацию в координатах ошибки относительно опорной траектории. В настоящей работе реализован lateral LQR с упрощением $e_y = 0$, оправданным постановкой навигации к точечной цели.

2.3. Иерархический RL и waypoint-планирование. Идея разбиения задачи управления на уровни различной временной абстракции восходит к option framework [7]. Современные иерархические схемы reinforcement learning представлены HIRO [5], в котором цели задаются в исходном пространстве с off-policy correction, и Director [6], в котором цели заданы в латентном пространстве world model. Между двумя крайностями располагается семейство схем с фиксированной верхнеуровневой структурой — waypoint-планировщики и классические геометрические алгоритмы навигации. В настоящей работе супервизорный уровень реализован простейшим геометрическим способом, что позволяет изолировать вклад модельного знания, отделяя его от вклада сложности алгоритма планирования.

2.4. STRL-парадигма и школа Осипова-Панова. Идея многоуровневой архитектуры мобильного робота сложилась в работах по поведенческой робототехнике 1990-х годов: Brooks обосновал subsumption architecture, Gat [8] систематизировал трёхуровневую организацию (deliberator-sequencer-controller), Arkin предложил поведенческие конечные автоматы для координации реактивных модулей. В школе Осипова-Панова эта линия получила развитие в направлении когнитивных агентов со знаковой картиной мира: операции на знаковых сетях с кортежем $s = \langle n, p, m, a \rangle$ (имя, образ, значение, смысл) [12] соединяют сенсомоторный опыт с понятийной структурой картины мира. Диссертационная работа [9] реализует Strategic-Tactical-Reactive Levels (STRL) для робототехнической платформы МП-РМ, с Q-обучением [10] атомарных действий на реактивном уровне и иерархическим планированием на верхних. Прямой предшественник настоящей

работы — статья [11] — расширяет программу школы в сторону мультимодальных сигналов и visual-language моделей; в её заключительной части обозначено направление дополнения VLM компонентой обучения с подкреплением и переход к интерактивной среде. Настоящая работа развивает указанное направление, реализуя парадигму STRL для непрерывного управления мобильным роботом в физическом симуляторе, и проводит количественный анализ распределения функций между уровнями — вопрос, который в дискретной постановке [9] не мог быть исследован систематически из-за ограничений тестовой платформы.

3. Метод

3.1. Постановка задачи. Рассматривается задача навигации мобильного робота к случайной целевой точке на плоской арене, возможно содержащей препятствия известной геометрии и варьируемой поверхностью под колёсами. Среда моделируется в физическом симуляторе PyBullet [13]; в качестве платформы используется Husky — четырёхколёсный робот с дифференциальным приводом, входящий в стандартную поставку симулятора. Управление осуществляется на уровне целевых угловых скоростей колёс, причём левая и правая пары рассматриваются как два управляющих канала, что эквивалентно стандартной формулировке differential-drive.

Задача формулируется как процесс принятия решений в марковской модели $\langle S, A, T, R, \gamma \rangle$. **Состояние** $s \in S$ образует вектор $o \in \mathbb{R}^{n_o}$ позы и кинематики робота, дополненный относительным положением цели и (для среды с препятствиями) лидарными измерениями; конкретный состав вектора зависит от экспериментальной установки. **Действие** $a \in [-1, 1]^2$ — нормированные целевые скорости левой и правой колёсных пар, преобразуемые в физические $\omega_{\text{wheel}} \in [-\omega_{\text{max}}, \omega_{\text{max}}]$ с $\omega_{\text{max}} = 10$ рад/с (линейная скорость робота до 1.7 м/с). **Функция перехода** T определяется физикой PyBullet с шагом симуляции 1/240 с; шаг управления 1/20 с, то есть одно действие удерживается двенадцать физических шагов. **Дисконт** $\gamma = 0.99$.

Арена — горизонтальная плоскость размером 10×10 м; робот стартует из центра, цель сэмплируется на расстоянии от 2 до 5 м от старта в случайном направлении, $d_{\text{goal}} = 0.4$ м — радиус достижения цели. **Условия завершения эпизода:** достижение цели (success), поворот робота на $> 60^\circ$ по тангажу или крену (failure), выход за пределы арены (failure), столкновение с препятствием (failure) или исчерпание лимита 500 шагов управления, что соответствует примерно 25 с реального времени (timeout).

Функция вознаграждения строится плотной — сумма штрафа за расстояние до цели и постоянного штрафа за каждый шаг, с дополнительными терминальными членами и средоспецифическими компонентами. При наличии

препятствий к базовой части добавляются плотный штраф за близость к препятствиям и терминальный штраф за столкновение.

Постановка отличается от стандартных бенчмарков непрерывного управления типа Reacher или HalfCheetah тем, что робот наделён неголономной кинематикой дифференциального привода и решает задачу пространственной навигации, а не локальной манипуляции. Это сближает её с практическими задачами мобильной робототехники.

3.2. Иерархическая архитектура управления. В качестве организующего принципа управления используется парадигма многоуровневой архитектуры, восходящая к ранним работам по поведенческой робототехнике и реактивным архитектурам [8], и развитая для случая когнитивных агентов в школе Осипова-Панова и конкретно в диссертационной работе [9], где обозначена как Strategic–Tactical–Reactive Levels (STRL). В STRL-парадигме поведение агента распределено по трём уровням, действующим в существенно разных временных масштабах и оперирующим разными моделями среды.

В настоящей работе реализована адаптация STRL для непрерывного управления мобильным роботом с дифференциальным приводом (рисунок 1). Три уровня выделяются следующим образом.

Реактивный уровень реализован обученной методом TD3 [1] нейросетевой политикой $\pi_{TD3} : o \mapsto a$, отображающей текущее наблюдение в нормированное двухкомпонентное действие. Этот уровень действует на каждом шаге управления (период 50 мс), оперирует только текущим наблюдением и в одиночку способен решать задачу навигации с приемлемым качеством в простых средах.

Тактический уровень реализован LQR-регулятором с фиксированным коэффициентом усиления, построенным на линеаризованной модели бокового движения differential-drive. Контроллер возвращает скалярную коррекцию $u_{LQR} \in [-u_{\max}, u_{\max}]$ к угловой скорости робота, комбинируемую с действием реактивного уровня в схеме Residual Policy [3, 4]. Тактический уровень действует на том же временном масштабе, что и реактивный, но опирается на явную аналитическую модель кинематики, что обеспечивает гладкость рулевого управления независимо от качества обучения нижнего уровня.

Супервизорный уровень реализован модулем обхода препятствий с использованием известной карты их положений (MapAware). Этот уровень получает на вход геометрию препятствий и вычисляет необходимость вмешательства: при приближении к любому препятствию в передней полусфере на расстояние ближе $d_{\text{takeover}} = 1.5$ м управление полностью передаётся супервизорному контроллеру до выхода из радиуса $d_{\text{release}} = 2.5$ м. Супервизорный уровень действует эпизодически — по необходимости перехватывая управление в опасных конфигурациях, тогда как в безопасной геометрии полностью отдаёт контроль реактивному и

тактическому уровням. Содержательно этот уровень играет роль того, что в классической STRL называется стратегическим уровнем, с тем уточнением, что в нашей реализации он не планирует последовательность подцелей, а supervisorно вмешивается на основе модели среды; в дальнейшем мы обсуждаем эту особенность в разделе ограничений.

Финальное действие, передаваемое в среду на каждом шаге управления, определяется правилом приоритета: при активном супервизорном уровне $a = a_{\text{MapAware}}$; иначе

$$a = a_{\text{TD3}} + \alpha \cdot \begin{bmatrix} -1 \\ +1 \end{bmatrix} u_{\text{LQR}}, \quad (1)$$

где знаки $-1, +1$ преобразуют скалярную поправку u_{LQR} в дифференциальный сигнал на колёса, а $\alpha \in [0, 1]$ — фиксированный весовой коэффициент. Результат покомпонентно ограничивается отрезком $[-1, 1]$. При $\alpha = 0$ и неактивном супервизоре архитектура вырождается в чистый TD3. В работе используется $\alpha = 0.2$, выбранное эмпирически как компромисс между подавлением высокочастотных колебаний рулевого управления и сохранением стратегических решений политики.




Рис. 1. Схема трёхуровневой иерархической архитектуры управления. Реактивный уровень (TD3) действует на каждом шаге; тактический (LQR-residual) корректирует курсовое движение; супервизорный (MapAware) перехватывает управление при приближении к препятствиям, положения которых известны.

3.3. Реактивный уровень: TD3. В качестве базовой политики реактивного уровня используется алгоритм TD3 [1] — off-policy актёр-критик для непрерывного управления с двойным критиком и задержанным обновлением актёра. Актёр и оба критика реализованы как полносвязные нейронные сети со скрытыми слоями размерности 400 и 300 и нелинейностью ReLU; выход актёра пропускается через

$\tanh$. Архитектура воспроизводит стандартную конфигурацию TD3 в реализации Stable-Baselines3 [14].

Гиперпараметры обучения: batch 256, оптимизатор Adam, скорость обучения 10^{-3} , $\tau = 0.005$, задержка обновления актёра $d = 2$, target-smoothing $\sigma = 0.2$ с обрезкой ± 0.5 . Шум исследования — гауссов $\mathcal{N}(0, 0.3)$. Размер replay-буфера 10^5 в пустой арене и $2 \cdot 10^5$ в среде с препятствиями. На каждый шаг сбора опыта приходится один градиентный шаг для каждого критика и (с учётом задержки) один шаг для актёра.

Наблюдение реактивного уровня включает позу робота, его линейные и угловые скорости, ориентацию (косинус и синус угла рыскания) и относительное положение цели. Такое наблюдение является *привилегированным* — оно эквивалентно идеальной локализации робота и точному знанию положения цели — что отделяет вопросы архитектуры управления от вопросов восприятия. В среде с препятствиями вектор расширяется лидарными измерениями (16 лучей в передней полусфере). Каждая модель обучается в одной заданной среде до выхода метрики evaluation reward на устойчивое плато; между моделями для разных сред веса не переносятся.

3.4. Tактический уровень: LQR-residual. Tактический уровень построен на линеаризованной модели бокового движения differential-drive. В системе координат, связанной с прямой, ведущей от робота к текущей цели, состояние ошибки выбирается двумерным: $e = [e_y, e_\theta]^\top$, где e_y — поперечное отклонение от опорной прямой, e_θ — отклонение курса. При фиксированной опорной линейной скорости v_{ref} и малых отклонениях линеаризованная модель ошибки принимает вид

$$\dot{e} = \begin{bmatrix} 0 & v_{\text{ref}} \\ 0 & 0 \end{bmatrix} e + \begin{bmatrix} 0 \\ -1 \end{bmatrix} \omega. \quad (2)$$

LQR находит оптимальное управление $\omega = -Ke$, минимизирующее квадратичный функционал

$$J = \int_0^\infty (e^\top Q e + \omega^\top R \omega) dt, \quad (3)$$

с весовыми матрицами $Q = \text{diag}(2.0, 1.0)$ и $R = 5.0$. Соотношение весов выбрано так, чтобы штраф на управление превышал штраф на отклонение курса: контроллер выдаёт мягкие, не доминирующие коррекции. Решение алгебраического уравнения Риккати выполнено численно средствами `scipy.linalg.solve_continuous_are`; матрица K вычисляется один раз при инициализации.

В реализации сделано существенное упрощение: компонента e_y обнуляется на каждом шаге управления. Причина — постановка задачи навигации к точечной цели: опорная прямая переопределяется на каждом шаге как линия из текущей

позы робота в текущую цель, и накопленного поперечного отклонения относительно этой динамической прямой не возникает. Закон управления вырождается в $\omega = -k_\theta e_\theta$, где k_θ — соответствующий элемент матрицы K . Структурно это Р-регулятор по углу с коэффициентом, выведенным из LQR-задачи. Такое сознательное упрощение оправдано тем, что в схеме Residual Policy LQR играет вспомогательную роль и должен подавлять высокочастотные колебания рулевого управления, не вмешиваясь в стратегические решения политики.

Скалярный выход ω ограничивается отрезком $[-u_{\max}, u_{\max}]$ с $u_{\max} = 0.3$ для гарантии того, что при патологических значениях e_θ поправка остаётся в безопасном диапазоне.

3.5. Супервизорный уровень: обход с использованием карты. Супервизорный уровень получает на вход карту препятствий — список троек $\{(o_i^x, o_i^y, r_i)\}$ цилиндрических препятствий с положениями центров и радиусами. В каждый момент времени уровень вычисляет расстояния и углы до всех препятствий в передней полусфере относительно курса робота, и применяет двупороговую логику: управление перехватывается, если минимальное расстояние до края препятствия в полусфере $\pm\pi/2$ относительно курса оказывается ниже $d_{\text{takeover}} = 1.5$ м, и возвращается реактивно-тактической паре, когда минимальное расстояние превышает $d_{\text{release}} = 2.5$ м. Гистерезис между порогами предотвращает дребезг управления вблизи границы.

Во время активного супервизорного режима контроллер задаёт прямолинейное движение со скоростью $v_{\text{sup}} = 0.4$ м/с и угловую скорость, поворачивающую робот от ближайшего препятствия:

$$\omega_{\text{sup}} = k_{\text{turn}} \cdot \text{sign}(-\theta_{\text{nearest}}), \quad (4)$$

где θ_{nearest} — локальный угол на ближайшее препятствие в передней полусфере, $k_{\text{turn}} = 1.5$. Логика преднамеренно проста: в задачах, где геометрия препятствий известна, эффективное поведение часто достижимо без оптимизационного планировщика. Это позволяет изолировать вклад *знания карты* как такового, отделяя его от вклада сложности конкретного алгоритма планирования.

Содержательно описанный супервизорный уровень не реализует стратегический синтез плана в классической STRL-парадигме [9]: он не предлагает последовательность подцелей, а перехватывает управление в опасных конфигурациях. Это сознательное упрощение, преследующее цель выделить роль модельного знания (известной карты) как такового. Расширение до полноценного стратегического уровня — адаптивного планировщика на основе известной карты — естественное направление развития работы, обсуждаемое в разделе 6.

Альтернативой супервизорному режиму на основе карты в работе также рассмотрена реактивная heuristic-схема обхода по лидарным дальностям (LidarAvoid).

Сравнение этих двух режимов друг с другом и с архитектурами без супервизора составляет основной экспериментальный материал раздела 4.

4. Эксперименты

4.1. Конфигурация и метрики. Все эксперименты проведены на вычислительном сервере (8 ядер Ryzen 9 9950X, 16 ГБ RAM, без GPU; обучение TD3 на CPU средствами Stable-Baselines3). Симулятор PyBullet 3.2 запускался в безголовом режиме с параллельным исполнением шести независимых сред через `SubprocVecEnv`. Все эксперименты с препятствиями детерминированы по седам $\{200, 201, \dots, 209\}$; для каждой конфигурации архитектуры и сценария проведено по $n = 10$ запусков, и таблицы ниже сообщают долю успешных эпизодов из десяти.

Основной метрикой служит *success rate* — доля эпизодов, завершившихся достижением целевой точки до `timeout`’а 500 шагов и без столкновения с препятствием. Дополнительно для качественного анализа фиксируются: средняя длина эпизода (число шагов управления), мера гладкости управления (средний модуль разности между последовательными командами на колёса), максимальная развитая линейная скорость, доля эпизода в супервизорном режиме.

Сравниваются пять архитектурных режимов, соответствующих включению/выключению тактического и супервизорного уровней:

- **TD3** — только реактивный уровень.
- **TD3+LQR** — реактивный и тактический уровни.
- **TD3+LidarAvoid** — реактивный и реактивный супервизор по лидару.
- **TD3+MapAvoid** — реактивный и модельный супервизор по карте.
- **TD3+MapAvoid+LQR** — все три уровня.

4.2. Эксперимент А: множественные конфигурации препятствий. В первой серии экспериментов оценивается зависимость распределения функций от геометрии препятствий. Используется семь детерминированных конфигураций препятствий, представляющих качественно разные ситуации навигации: одиночное препятствие на прямой к цели; два препятствия со смещением; коридор из трёх препятствий; барьер с проходом; слалом из четырёх препятствий; диагональное расположение цели; широкое препятствие. В каждой конфигурации цель располагается в фиксированной точке, геометрия препятствий полностью известна супервизорному уровню.

Данные таблицы 1 демонстрируют существенно неравномерное распределение успеха по сценариям и режимам. Сценарий *diagonal_goal* не содержит препятствий на прямой к цели, и все пять режимов справляются с ним полностью. Это служит саниксом: реактивный уровень не деградирует при включении

Сценарий	TD3	+LQR	+Lidar	+Map	+Map+LQR
single_on_line	0/10	0/10	0/10	10/10	10/10
two_offset	0/10	0/10	0/10	10/10	10/10
three_corridor	0/10	0/10	0/10	0/10	0/10
barrier_with_gap	10/10	10/10	10/10	0/10	0/10
slalom	0/10	0/10	0/10	0/10	0/10
diagonal_goal	10/10	10/10	10/10	10/10	10/10
wide_obstacle	0/10	0/10	10/10	10/10	10/10

Таблица 1. Эксперимент А: success rate (из 10 запусков на сидах 200–209) для семи конфигураций препятствий и пяти архитектурных режимов. Все ячейки 100% детерминированы: повторные запуски в идентичной конфигурации дают идентичный исход.

тактического или супервизорного уровней. Сценарии *three_corridor* и *slalom* не решаются ни одним режимом — они выходят за пределы возможностей данной архитектуры и фиксируют верхнюю границу её применимости.

Содержательное различие проявляется на оставшихся четырёх сценариях. В *single_on_line* и *two_offset* разница между режимами максимальна: только включение супервизорного уровня (TD3+MapAvoid, TD3+MapAvoid+LQR) даёт 100% успех, в то время как реактивный и тактический уровни в одиночку или в комбинации не справляются. На уровне траекторий видно, что обученная TD3-политика идёт по прямой в финальную цель, не учитывая препятствие, и сталкивается с ним; LQR-residual подавляет колебания курса, но не меняет общую стратегию. Только супервизорный уровень с явным знанием карты способен перенаправить движение, не нарушая итоговый успех.

Обратный паттерн наблюдается в сценарии *barrier_with_gap*, где прямой путь к цели проходит через узкий проход в барьере. Здесь все архитектуры, опирающиеся на супервизорный уровень MapAvoid, не справляются (0/10), а полностью реактивные (TD3, TD3+LQR) и реактивный с лидарным супервизором (TD3+Lidar) справляются полностью. Причина видна в логике MapAvoid: широкий радиус takeover ($d_{\text{takeover}} = 1.5$ м) заставляет супервизор инициировать обход барьера в обход прохода, тогда как геометрический проход в барьере проходим напрямую. Реактивная политика, обученная на разнообразной геометрии, проходит через проход успешно.

Наконец, в сценарии *wide_obstacle* наибольшую устойчивость показывает лидарный супервизор: широкое препятствие не маркировано в карте как протяжённое (используется аппроксимация цилиндром малого радиуса), и MapAvoid не активируется на нужной дистанции, тогда как лидарные лучи фиксируют

препятствие напрямую. Это указывает на ограниченность модельного знания: оно полезно, но требует адекватной геометрической репрезентации препятствий.

Воспроизводимость. Все сорок ячеек в таблице 1 проверены повторными запусками в идентичной конфигурации. Результаты полностью детерминированы: каждая ячейка имеет однозначный исход, 10/10 или 0/10, без промежуточных значений на десяти сидах. Это свойство сцены, а не статистики, и оно следует из детерминированности PyBullet при фиксированных стартовых условиях, фиксированных весах обученной политики и отсутствия стохастичности в супервизорном и тактическом уровнях.

4.3. Эксперимент В: переменные свойства поверхности. Во второй серии оценивается влияние свойств опорной поверхности на работу архитектуры. Реализованы три условия: *NORMAL* (коэффициент трения 0.9, базовая поверхность), *ICE* (коэффициент трения 0.05, скользкая поверхность, имитирующая лёд) и *SAND* (коэффициент трения 0.6 с дополнительным сопротивлением качению, имитирующая мягкий грунт). Каждое условие тестируется в двух конфигурациях: *empty* — пустая арена с целью, *with_obstacle* — арена с препятствием, для которого известна карта. Каждая ячейка содержит десять запусков на сидах 200–209.

Поверхность	Конфиг.	TD3	+LQR	+Lidar	+Map	+Map+LQR
NORMAL	empty	10/10	10/10	10/10	10/10	10/10
NORMAL	+ obst.	0/10	0/10	0/10	10/10	10/10
ICE	empty	10/10	10/10	10/10	10/10	10/10
ICE	+ obst.	0/10	0/10	0/10	0/10	0/10
SAND	empty	10/10	10/10	10/10	10/10	10/10
SAND	+ obst.	0/10	0/10	0/10	10/10	10/10

Таблица 2. Эксперимент В: success rate (из 10 запусков) для трёх типов поверхности и двух конфигураций. Модель TD3 v3 обучена на детерминированном сценарии с препятствием на NORMAL и используется во всех ячейках без переобучения.

Таблица 2 разделяет два эффекта. В пустой арене реактивный уровень одинаково успешен на всех трёх поверхностях, хотя максимальная развитая скорость различается на порядок (на ICE робот вынужден двигаться вдвое медленнее, чтобы не соскользнуть; на SAND — медленнее на четверть). Это означает, что обученная политика обладает достаточной общностью для адаптации линейной скорости под трение, хотя обучение проводилось только на NORMAL.

В присутствии препятствия картина существенно меняется. На NORMAL и SAND включение супервизорного уровня MapAvoid полностью решает задачу

(10/10 в обоих случаях), что согласуется с результатами эксперимента А в сценарии *single_on_line*. Однако на ICE с препятствием ни один из режимов не решает задачу: при попытке обхода препятствия низкое трение приводит к проскальзыванию колёс, робот заносит, и столкновение происходит даже при идеальной стратегии обхода. Это указывает на принципиальное ограничение архитектуры: *знание карты не компенсирует физическое ограничение нижнего уровня*.

Для проверки этой гипотезы было проведено дополнительное дообучение TD3-политики на расширенной выборке поверхностей (continued training на 700 тыс. шагов с распределением 50%/30%/20% между NORMAL/SAND/ICE). Получившаяся модель показала улучшение ICE+obstacle с 0/10 до 5/10 в комбинации с тактическим уровнем, но регрессию на NORMAL+obstacle с 10/10 до 7/10 в режиме MapAvoid+LQR. Это эмпирически фиксирует trade-off между общностью и пиковой скоростью на отдельно взятой поверхности, известный в литературе для transfer learning, и формирует естественное ограничение применимости архитектуры в текущем виде.

5. Обсуждение

Эмпирические результаты раздела 4 позволяют сформулировать несколько содержательных наблюдений о распределении функций между уровнями рассмотренной иерархической архитектуры.

Реактивный уровень компетентен в условиях свободного движения. В пустой арене и на всех трёх типах поверхности (NORMAL, ICE, SAND) обученная TD3-политика достигает 100 % успеха, демонстрируя способность адаптировать линейную скорость под условия трения без переобучения. Это совпадает с типичной областью применения reactive control в STRL-парадигме: действие на коротком горизонте без обращения к модели среды.

Тактический уровень не меняет стратегические решения. Включение LQR-residual на верхушке реактивного уровня не меняет success rate ни в одной из исследованных ячеек — ни в эксперименте А (таблица 1), ни в эксперименте В (таблица 2). Качественно LQR подавляет высокочастотные колебания курсового управления, что фиксируется в метрике гладкости (снижение на $\sim 10\%$, согласно дополнительным измерениям), но не влияет на способность преодолевать препятствия или соскальзывать с поверхности. Это согласуется с теоретической ролью тактического уровня в STRL [9] и подтверждает, что упрощение $e_y = 0$ в lateral LQR не лишает регулятор полезной функции.

Супервизорный уровень разгружает реактивный там, где модельное знание адекватно. Эксперимент А показывает, что в сценариях, где препятствие лежит на прямой к цели (*single_on_line*, *two_offset*), реактивный уровень

не справляется в одиночку, но включение супервизорного с MapAware-логикой обеспечивает 100 % успех. Это типичная демонстрация полезности стратегического уровня в STRL: знание среды позволяет принимать решения, которых реактивный уровень, действующий по сенсорному наблюдению, принять не может. Однако в сценарии *barrier_with_gap* мы наблюдаем обратный эффект: супервизор перехватывает управление при приближении к барьеру и заставляет робот обойти его, тогда как геометрически проход проходим. Это указывает на чувствительность супервизорного уровня к параметрам геометрической модели препятствий и к структуре алгоритма обхода.

Модельное знание не компенсирует физическое ограничение нижнего уровня. Эксперимент В даёт принципиальное наблюдение: на ICE с препятствием ни один из режимов не решает задачу, включая полностью трёхуровневую архитектуру TD3+MapAvoid+LQR. Супервизор предлагает корректную стратегию обхода, тактический уровень обеспечивает гладкое управление, но низкое трение приводит к проскальзыванию и столкновению независимо от стратегии. Иными словами, разгрузка реактивного уровня по высоким абстракциям не работает, когда сам реактивный уровень упирается в физический предел (*disturbance* не парируется *policy*, обученной на нормальном трении). Эксперимент с дополнительным дообучением политики на расширенном распределении поверхностей частично снимает это ограничение, но формирует *trade-off* с пиковой скоростью на отдельно взятой поверхности.

Общая трактовка — эффект STRL-распределения зависит от среды. Полезность каждого верхнего уровня архитектуры не абсолютна, а функционально определена структурой среды и качеством нижних уровней. В средах со свободным движением полезность тактического и супервизорного уровней нулевая или отрицательная (внесение дополнительных степеней свободы без выигрыша в успехе). В средах с известной геометрией препятствий супервизорный уровень становится критически важен. В средах с физическими ограничениями нижнего уровня (низкое трение) ни один из верхних уровней не компенсирует ограничение.

Ограничения работы. В работе использован простейший геометрический супервизор без оптимизационного планирования; реактивный уровень обучен с привилегированным наблюдением (идеальная локализация и точное знание положения цели); реальная робототехническая платформа не задействована. Эти ограничения определяют направления развития, обсуждаемые в заключении.

6. Заключение

В работе реализована и эмпирически исследована трёхуровневая иерархическая архитектура управления мобильным роботом с дифференциальным при-

водом, соотносимая с парадигмой STRL школы Осипова-Панова. Реактивный уровень реализован обученной методом TD3 нейросетевой политикой, тактический — LQR-residual с упрощением $e_y = 0$, супервизорный — модулем обхода препятствий по известной карте.

Ablation-анализ на двух семействах сценариев — семи конфигураций препятствий и трёх типах поверхности — позволяет количественно охарактеризовать распределение функций между уровнями. Тактический уровень не меняет success rate, но улучшает гладкость управления. Супервизорный уровень разгружает реактивный в задачах с известной геометрией препятствий, но не справляется в условиях слабого сцепления колёс с поверхностью — модельное знание не компенсирует физических ограничений нижнего уровня. Все результаты воспроизведены при $n = 10$ запусках на детерминированных седах со 100% воспроизводимостью.

Направления развития работы естественно следуют из выявленных ограничений. **Стратегический уровень** в его полной STRL-формулировке — оптимизационный планировщик, выдающий последовательность подделей на длинном горизонте, а не supervisorно перехватывающий управление, — требует реализации и сравнения с использованным здесь упрощённым вариантом. **Visual-language интерфейс** к стратегическому уровню, в духе прямого предшественника [11], естественно дополняет архитектуру визуальной модальностью и связывает её с программой школы Осипова-Панова в её современной формулировке. **Реальный робот** как тестовая платформа — ключевое направление, на котором традиционно сосредоточена работа группы [9]; перенос архитектуры из PyBullet на платформу с интерфейсом ROS требует адаптации наблюдения (восстановление позы из SLAM) и проверки устойчивости обученной политики к sim-to-real разрыву.

ЛИТЕРАТУРА

1. Fujimoto S., van Hoof H., Meger D. Addressing function approximation error in actor-critic methods // Proc. of ICML. 2018. P. 1587–1596.
2. Mnih V., Kavukcuoglu K., Silver D. et al. Human-level control through deep reinforcement learning // Nature. 2015. V. 518. P. 529–533.
3. Silver T., Allen K., Tenenbaum J., Kaelbling L. Residual policy learning // arXiv preprint arXiv:1812.06298. 2018.
4. Johannink T., Bahl S., Nair A. et al. Residual reinforcement learning for robot control // Proc. of ICRA. 2019. P. 6023–6029.
5. Nachum O., Gu S., Lee H., Levine S. Data-efficient hierarchical reinforcement learning // Proc. of NeurIPS. 2018. P. 3303–3313.
6. Hafner D., Lee K.-H., Fischer I., Abbeel P. Deep hierarchical planning from pixels // Proc. of NeurIPS. 2022.

7. Sutton R. S., Precup D., Singh S. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning // Artificial Intelligence. 1999. V. 112. P. 181–211.
8. Gat E. On three-layer architectures // Artificial Intelligence and Mobile Robots / D. Kortenkamp, R. Bonasso, R. Murphy (eds.). AAAI Press, 1998. P. 195–210.
9. Киселёв Г. А. Интеллектуальная система планирования поведения коалиции робототехнических агентов со STRL архитектурой: дис. . . . канд. техн. наук. Москва, 2020. 117 с.
10. Киселёв Г. А., Панов А. И. Иерархическое психологически-инспирированное планирование для интеллектуальных динамических систем // Известия РАН. Теория и системы управления. 2020. № 1. С. 123–137.
11. Вейценфельд Д. А., Киселёв Г. А. Метод синтеза поведения когнитивного агента на основе обработки мультимодальных сигналов // Моделирование и анализ данных. 2024. Т. 14. № 4. С. 45–62.
12. Osipov G. S., Panov A. I. Relationships and operations in a sign-based world model of the actor // Scientific and Technical Information Processing. 2018. V. 45. P. 317–330.
13. Coumans E., Bai Y. PyBullet, a Python module for physics simulation for games, robotics and machine learning. 2016–2021. URL: <http://pybullet.org>
14. Raffin A., Hill A., Gleave A. et al. Stable-Baselines3: Reliable reinforcement learning implementations // Journal of Machine Learning Research. 2021. V. 22. № 268. P. 1–8.